

RAPPORT

SAE 206

ETAPE 1

19/04/2026

Salman Patel

Mohamed Boustane

Jouri Ademe

Adam Belhadi

Nizar Abdou

Rayane Zouiti

Table des matières:

- I. Description des données
- II. Nettoyage des données
- III. Exploration et Traitement des données
- IV. Visualisation

I. Description des données

Pour réaliser cette étude de marché, nous nous sommes appuyés sur la base de données du fournie par l'INSEE. Ce jeu de données de référence recense de manière exhaustive les caractéristiques socio-économiques de l'ensemble du territoire français à l'échelle des communes.

Il y'a 2 fichiers essentiels :

-**Dossier_complet.csv**

Lignes : 34988

Colonnes : 1975

-**Meta_dossier_complet.csv**

Lignes : 71816

Colonnes : 9

Dossier_complet.csv est un fichier très volumineux, pour chaque ligne on a une commune ainsi que tout ses indicateurs socio-economique. Chaque commune est identifié par un code commune CODEGEO. Chaque colonne du fichiers contient les valeurs des indicateurs.

Le fichier meta dossier complet est très important pour comprendre le jeu de données, on va l'utiliser pour cette partie de description. Il permet de comprendre la signification des variables.

Chaque lignes représentent un colonne du fichier données principal, Il nous permet de savoir :

-Le nom de la colonne

-sa description

-Le thème auquel elles sont associés.

A l'aide du module pandas sur python, on va voir les informations à savoir sur le jeu de données et le fichier meta données. On établit le code SAE Description suivant :

0.

```
[2]: import pandas as pd
```

1.

```
*[3]: df_meta = pd.read_csv("meta_dossier_complet.csv", sep=";", low_memory=False)
df = pd.read_csv('dossier_complet.csv', sep=';', low_memory = False)
```

2.

On affiche le nombre de lignes et de colonnes.

```
[6]: print('dossier complet')
df.shape
print('meta')
```

```
dossier complet
meta
```

On importe le dossier meta données et dossier_complet avec la fonction .readcsv

L'étape 2 affiche le tuple (lignes,colonnes)

2.

On affiche le nombre de lignes et de colonnes.

```
[8]: print('dossier complet')
      print(df.shape)
      print('meta')
      print(df_meta.shape)

dossier complet
(34988, 1976)
meta
(71815, 9)
```

Le dossier compte 34988 lignes et 1976 colonnes

```
[11]: df.isnull().sum()

[11]: CODGEO      0
      P22_POP      89
      P22_POP0014  89
      P22_POP1529  89
      P22_POP3044  89
      ..
      BPE_2024_D277 72
      BPE_2024_D279 72
      BPE_2024_D281 72
      BPE_2024_D307 72
      BPE_2024_F307 72
      Length: 1976, dtype: int64
```

L'instruction `df.isnull.sum()` renvoie le total de cases vides pour chaque colonnes du data frame.

3.

```
[24]: df_vars = df_meta.drop_duplicates(subset="COD_VAR")  #Donne la repartition des variables
      df_vars["TYPE_VAR"].value_counts()

[24]: TYPE_VAR
      NUM      1948
      CHAR      28
      Name: count, dtype: int64
```

7.

```
[22]: df_num = df_meta.loc[df_meta["TYPE_VAR"] == "NUM"].drop_duplicates(subset="COD_VAR")
      df_num["THEME"].value_counts()

[22]: THEME
      Caractéristiques de l'emploi au sens du recensement      345
      Évolution et structure de la population                300
      Logement                                                  284
      Couples - Familles - Ménages                            245
      Démographie des entreprises                             194
      Diplômes - Formation                                    189
      Population active, emploi et chômage au sens du recensement 172
      Caractéristiques des établissements                      82
      Tourisme                                                  51
      Salaires et revenus d'activité                           30
      Équipements et services                                  24
      Naissances et décès domiciliés                           22
      Élections                                                  4
      Name: count, dtype: int64
```

Cette partie du code nous donne la répartition des types des variables, le nombre de variable qui sont numériques et le nombre de variables qui sont des chaînes de caractère.

```
df_num = df_meta.loc[df_meta["TYPE_VAR"] == "NUM"].drop_duplicates(subset="COD_VAR")
df_num["THEME"].value_counts()
```

Ces instructions nous permettent de savoir à partir du fichier meta données, le nombre de colonnes appartenant à chaque thème.

Afin de faciliter le choix des variables pour les prochaines étapes, on a décidé de regrouper chaque variable avec son thème associé dans un fichier excel, pour mieux cerner les variables. Pour cela, on va utiliser le module pandas sur python.

```

df_meta = pd.read_csv("meta_dossier_complet.csv", sep=';', low_memory = False)

# On enlève Les thèmes vides
df_meta = df_meta.dropna(subset=['THEME'])
liste_themes = df_meta['THEME'].unique()

print("C'est parti pour la création des lexiques !\n")

for theme in liste_themes:

    # 2. On prépare nos listes à la main (avec CODGEO en premier)
    liste_codes = ["CODGEO"]
    liste_descriptions = ["Code de la commune"]

    # 3. On isole le thème actuel
    dico_theme = df_meta[df_meta['THEME'] == theme]

    # On transforme les colonnes en listes Python classiques
    codes_insee = list(dico_theme['COD_VAR'])
    textes = list(dico_theme['LIB_VAR'])

    # 4. La boucle la plus simple du monde pour remplir nos listes
    for i in range(len(codes_insee)):
        liste_codes.append(codes_insee[i])
        liste_descriptions.append(textes[i])

    # 5. On crée un tableau vide, et on met nos listes dedans
    tableau_final = pd.DataFrame()
    tableau_final['Code_Variable'] = liste_codes
    tableau_final['Description'] = liste_descriptions

    # 6. On sauvegarde en Excel
    nom_fichier = theme + ".xlsx"

    tableau_final.to_excel(nom_fichier, index=False)

    print("Fichier créé : " + nom_fichier)

print("\nTerminé !")

```

Ce code nous permet d'avoir un fichier excel pour chaque thème, et donc d'avoir les colonnes associés.

Pour éviter de perdre du temps à parcourir les fichiers, on importe toutes les données des fichiers, dans un seul fichier excel à l'aide de power query. [Meta donne trie](#)

Cela va nous permettre de mieux observer ce qui caractérise ces colonnes.

En observant les différentes variables pour chaque thème, on obtient ce [tableau](#) :

PRÉFIXE	SIGNIFICATION	CE QU'ELLE FAIT	TYPES
CODGEO	Code géographique insee	Identifiant unique d'une commune ou d'un territoire (code commune INSEE)	Identifiant/clé primaire
P	Population Totale recencée	Données de population issues du recensement général de la population de selon l'année(effectifs, répartition par âge, sexe, statut...)	Quantitative discrète
C	Caractéristiques sociales	Caractéristiques structurelles(ménages, logements, familles,emplois, etc...)	Quantitative discrète
D	Données/diplômes	Variables relatives aux diplômes et niveaux de formation issus du recensement (P ou C selon contexte)	Quantitative discrète
SNEMM_	Salaire net moyen en équivalent temps plein mensuel	Salaire net moyen mensuel en EQTP par sexe, âge et catégorie socio-professionnelle	Quantitative continue
BPE_	Base permanente des équipements	Nombre et type d'équipements et services présents sur le territoire (écoles, médecins, commerces...)	Quantitative discrète
ETC	Entreprises créés par secteurs d'activités	millésime 2024	Quantitative discrète
ETP	Établissements : Parts/Proportion	Nombre de créations d'entreprises par secteur d'activité (codes NAF/APE) et par année	Quantitative continue
ENCI	Entreprises créés : individuelles	Part (%) des établissements selon leur taille ou secteur d'activité	Quantitative discrète
ENCTOT	Entreprises créés : total	Nombre de créations d'entreprises sous forme individuelle(auto-entrepreneur...)	Quantitative continue
ETAZ	Établissements: Secteur agriculture	Nombre total de créations d'entreprises toutes formes confondues, par année	Quantitative discrète
ETBE	Établissements : Secteur construction	Nombre d'établissements dans le secteur agricole(section A de la NAF)	Quantitative discrète
ETZF	Établissements : Secteur commerce/transports	Nombre d'établissements dans le secteur de la construction (section F)	Quantitative discrète
ETGU	Établissements : Secteur services aux entreprises	Nombre d'établissements dans le commerce, transports, hébergement-restauration	Quantitative discrète
ETOQ	Établissements : Secteur administration/santé(OQ)	Nombre d'établissements dans les services aux entreprises et activités financières	Quantitative continue
ETEF	Établissements : Tranche d'effectif salarié	Nombre d'établissements dans l'administration publique, enseignement, santé, action sociale	Quantitative discrète
ETTOT	Établissements : Total	Nombre d'établissements selon leur tranche d'effectif (0 ,1-9, 10-49, 50-249, 250+)	Quantitative discrète
NAISD	Naissances domiciliés	Nombre total d'établissements actifs sur le territoire	Quantitative continue
DECESD	Décès domiciliés	Nombre de naissances domiciliées dans la commune par année (de 2014 à 2024)	Quantitative discrète
NAIS	Naissances	Nombre de décès domiciliés dans la commune par année (de 2014 à 2024)	Quantitative discrète
DECE	Décès	Données sur les naissances issues des statistiques d'état civil (structure de la population)	Quantitative discrète
TP60	Taux de pauvreté à 60 % du revenu médian	Données sur les décès issues des statistiques d'état civil (structure de la population)	Quantitative continue
HT	Hôtels : capacité touristique	Taux de pauvreté et indicateurs de distribution des revenus, déclinés par âge, type de ménage et composition familiale	Quantitative continue
HTCH	Hôtels : chambres	Nombre d'hôtels et de chambres disponibles par catégorie d'étoiles sur le territoire	Quantitative discrète
CPG	Camping : capacité d'accueils	Nombre de chambres d'hôtel par catégorie d'étoiles (complément de HT)	Quantitative discrète
CPGE	Campings : Emplacements	Nombre de campings et d'emplacements par catégorie d'étoiles sur le territoire	Quantitative continue
VV	Villages vacances : capacités	Détail des emplacements de camping par type et catégorie (locations, emplacements ...)	Quantitative continue
RT	Residence de tourisme	Nombre de villages vacances et lits touristiques associés	Quantitative continue
AJCS	Auberge de jeunesse et centres sportifs	Nombre de résidences de tourisme et capacité en lits (unités d'hébergement)	Quantitative continue
ELECTEURSLP	Électeurs : Listes politiques	Nombre de lits en auberges de jeunesse et centres de vacances	Quantitative continue
NBMENFISC	Nombre de ménages fiscaux	Nombre d'électeurs inscrits sur les listes politiques par année électorale (2020, 2021, 2022, 2024)	Quantitative continue
NSPERSMENFISC	Nombre de personnes dans les ménages fiscaux	Nombre de foyers fiscaux sur le territoire (source DGFiP)	Quantitative continue
MED	Médianes des revenus	Nombre total de personnes appartenant à un foyer fiscal déclarant	Quantitative continue
PIMP	Part des impositions	Revenu médian disponible par unité de consommation sur le territoire	Quantitative continue
PACT	Part des revenus d'activité	Part des foyers fiscaux imposés sur le revenu (%)	Quantitative continue
PTSA	Part des revenus de transfert salarial	Part des revenus d'activité salariée dans le revenu disponible des ménages	Quantitative continue
PCHO	Part des allocations chômage	Part des indemnités de chômage et autres transferts liés à l'emploi dans le revenu	Quantitative continue
PBEN	Part des bénéfices non salariaux	Part des allocations chômage dans le revenu disponible des ménages	Quantitative continue
PPEN	Part des pensions et retraites	Part des bénéfices des travailleurs indépendants dans le revenu	Quantitative continue
PPAT	Part des revenus du patrimoine	Part des pensions, retraites et rentes dans le revenu disponible des ménages	Quantitative continue
SUPERF	Superficie communale	Part des revenus du patrimoine (loyers, dividendes...) dans le revenu des ménages	Quantitative continue
ETN	Établissements : net(fermetures)	Superficie totale de la commune en km²	Quantitative continue
ENN	Établissements : net(trêve)	Nombre d'établissements ayant cessé leur activité (fermetures nettes) par secteur	Quantitative continue
		Nombre d'entreprises ayant cessé définitivement leur activité par secteur	Quantitative discrète

Chaque préfixe a une signification, un rôle, et un type. Il y’a un total de 48 catégories de variables possible.

On a aussi fait une liste descriptive des différents thèmes du jeu de données

Thème	Spécificité	Type de données	Nombre
Caractéristiques de l'emploi au sens du recensement	Détaille les conditions de travail des habitants. On y trouve le type de contrat (CDI, CDD, temps partiel), le statut (salarié, indépendant) et les catégories socio-professionnelles (cadres, ouvriers, employés)	Quantitative discrète	345
Évolution et structure de la population	C'est la démographie pure. Ces colonnes comptent le nombre d'habitants en les croisant par tranches d'âge très précises et par sexe (par exemple : le nombre d'hommes de 15 à 29 ans, le nombre de femmes de plus de 75 ans)	Quantitative discrète	300
Logement	Décrit l'habitat de la commune. Cela inclut le type de construction (maisons ou appartements), le statut d'occupation (locataires ou propriétaires), la taille (nombre de pièces) et le type de résidence (principale, secondaire ou autre)	Quantitative discrète	284
Couples – Familles – Ménages	Analyse la composition des foyers. On y trouve le nombre de personnes vivant seules, les familles monoparentales, et les couples avec ou sans enfants	Quantitative discrète	245
Démographie des entreprises	Mesure le dynamisme économique local en comptant les créations de nouvelles entreprises et les disparitions, souvent triées par secteur d'activité	Quantitative discrète	194
Diplômes – Formation	Évalue le niveau d'éducation de la population (sans diplôme, niveau bas, études supérieures, etc.) ainsi que les effectifs de personnes actuellement scolarisées	Quantitative discrète	189
Population active, emploi et chômage au sens du recensement	Définit le statut des individus face au marché du travail. On y dénombre la population active occupée (ceux qui travaillent), les chômeurs, ainsi que les inactifs (étudiants, retraités)	Quantitative discrète	172
Caractéristiques des établissements	S'intéresse aux structures physiques implantées sur le territoire (les usines, les bureaux, les boutiques) et à leur taille (nombre de salariés sur place)	Quantitative discrète	82
Tourisme	Évalue la capacité d'accueil pour les visiteurs extérieurs. Cela correspond au nombre de chambres d'hôtels, aux emplacements de camping et aux lits touristiques	Quantitative discrète	51
Salaires et revenus d'activité	Regroupe les données financières comme le salaire horaire moyen, les indicateurs de niveau de vie ou encore les taux de pauvreté de la zone	Quantitative continue	30
Équipements et services	Liste les infrastructures du quotidien disponibles dans la commune, telles que les boulangeries, les médecins généralistes, les écoles ou les équipements sportifs	Quantitative discrète	24
Naissances et décès domiciliés	Il s'agit simplement de l'état civil, avec le dénombrement annuel des nouveau-nés et des personnes décédées domiciliées dans la ville	Quantitative discrète	22
Élections	Quelques indicateurs très spécifiques concernant les inscrits sur les listes électorales ou la participation	Quantitative discrète	4

II.Nettoyage des données

Après avoir compris le jeu de données, on a décider de nettoyer le fichier.

Le fichier dossier_complet est très volumineux et contient très surement des colonnes avec des valeurs vides, ou des informations classé « secrete », ou même des colonnes mal typés.

Notre objectif est de :

-Vérifier que chaque colonne à le bon type de donnée

-Remplacer les lignes sans valeur, ou classé secrete par des 0.

-Enlever les colonnes qui sont presque vides.

On va utiliser python encore une foi pour cette étape.

Voici le code qu’on a mis en place pour nettoyer le fichier.

3. ON REGARDE LES COLONNES MAL TYPEES

```
[9]: meta = pd.read_csv('meta_dossier_complet.csv', sep=';', low_memory=False)
meta = meta.drop_duplicates(subset='COD_VAR')[['COD_VAR', 'TYPE_VAR']]
#Import fichier meta
mal_typees = []

for i in range(len(meta)): #On creer une boucle qui parcourt Les indices du dataframe meta
    cod = meta['COD_VAR'].iloc[i]
    type_attendu = meta['TYPE_VAR'].iloc[i]

    if cod in df.columns: #Pour chaque colonne du data frame principale
        if type_attendu == 'NUM' and df[cod].dtype == 'object': #si Le type de la colonne est un texte
            mal_typees.append(cod) #elle rentre dans la liste des mal types

print('Colonnes mal typées :', mal_typees)

0 859.0
```

Cette partie du code nous sert à vérifier que le type de chaque colonne soit conforme au fichier meta données. On parcourt tout le dataframe, avec la boucle `for i in range`

À chaque passage de la boucle, on isole le code de la variable (qui provient du fichier meta) que l'on est en train d'analyser (par exemple, "MED21") dans la variable `col`.

La variable `type_attendu` conserve le format attendu de cette même variable.

« `if cod in df.columns` », permet de vérifier que la variable est bien présente dans notre tableau de données.

“`if type_attendu == 'NUM' and df[cod].dtype == 'object':`”, la variable est de type `object` donc une chaîne de caractère, et que le type attendu est 'NUM', un entier, la variable rentre dans la liste des colonnes mal types

```
[13]: df = df.replace(['s', 'nd'], 0) #On remplace Les cases contenant 'nd' ou 's' par 0

cols_texte = []
for c in df.select_dtypes('object').columns:
    if c != 'CODEGEO':
        cols_texte.append(c)

for col in cols_texte:
    df[col] = df[col].str.replace(',', '.', regex=False)
    df[col] = df[col].astype(float)

print('Colonne Modifiée')
print(len(cols_texte), 'colonnes corrigées')
```

Le fichier de l'INSEE, contient des données classées secrètes ou des données non renseignées.

En utilisant `df.replace`, on remplace tout les 's' ou 'nd' par 0.

La deuxième boucle consiste à transformer en flottant les valeurs qui pourraient être en texte

5. Suppression des colonnes trop vides

On supprime les colonnes avec plus de 90 % de valeurs manquantes.

```
[17]: avant = df.shape[1] #nombres de colonnes avant nettoyages

df = df.loc[:, df.isnull().mean() <= 0.90] #On prend toutes Les lignes, on prend que Les colonnes vide a moins de 90 pourcent
print('Colonnes supprimées :', avant - df.shape[1])
print('Dimensions finales :', df.shape)

Colonnes supprimées : 30
Dimensions finales : (34988, 1946)
```

Cette partie consiste au nettoyage des colonnes vides.

En utilisant la fonction `loc`, permettant de localiser les lignes du dataframe, on recrée le dataframe :

[:] prend toutes les lignes du tableau, [df.isnull.mean() <= 0.90] signifie qu'on ne conserve que les colonnes dont la moyenne de valeurs vides est inférieur ou égale à 90 pourcent.

Pour pouvoir repérer les variables supprimé, on fait une variable avant qui contient le nombres de colonnes avant nettoyage.

On fait un affichage de l'ancien nombre de colonnes moins le nombre du colonne du nouveau data frame.

III. Exploration des données

Pour cette partie, notre axe d'étude va porter sur l'hôtellerie de luxe. En consultant le fichier meta_dossier_trie avec toutes les catégories triés

-Tourisme

-Revenus et pauvreté des ménages

-Logement

-Evolution et structure de la population

-Population active et Diplomes-Formations

```

•[6]: import pandas as pd

# 1. On charge le fichier complet nettoyé
df = pd.read_csv("dossier_complet_clean.csv", sep=';')

# 1. LES HOTELS 5 ÉTOILES
print("\nTop 10 : Hôtels 5 étoiles ")
tri_h5 = df.sort_values(by='HT526', ascending=False)
print(tri_h5[['CODGEO', 'HT526']].head(10))

# 2. LES HOTELS 4 ÉTOILES
print("\nTop 10 : Hôtels 4 étoiles ")
tri_h4 = df.sort_values(by='HT426', ascending=False)
print(tri_h4[['CODGEO', 'HT426']].head(10))

# 3. LES CHAMBRES 5 ÉTOILES
print("\n--- Top 10 : Chambres 5 étoiles ")
tri_ch5 = df.sort_values(by='HTCH526', ascending=False)
print(tri_ch5[['CODGEO', 'HTCH526']].head(10))

# 4. LES CHAMBRES 4 ÉTOILES
print("\nTop 10 : Chambres 4 étoiles ")
tri_ch4 = df.sort_values(by='HTCH426', ascending=False)
print(tri_ch4[['CODGEO', 'HTCH426']].head(10))

# 5. LA CLIENTÈLE SENIOR (60-74 ans)
print("\nTop 10 : Habitants entre 60 et 74 ans ")
tri_seniors = df.sort_values(by='P22_POP6074', ascending=False)
print(tri_seniors[['CODGEO', 'P22_POP6074']].head(10))

# 6. LA CLIENTÈLE D'AFFAIRES (Cadres)
print("\nTop 10 : Nombre de cadres ")
tri_cadres = df.sort_values(by='C22_EMPLT_GS3', ascending=False)
print(tri_cadres[['CODGEO', 'C22_EMPLT_GS3']].head(10))

# 6. LE REVENU MÉDIAN (Richesse globale)
print("\n--- Top 10 : Communes avec le Revenu Médian le plus élevé")
tri_revenu = df.sort_values(by='MED21', ascending=False)
print(tri_revenu[['CODGEO', 'MED21']].head(10))

# 7. LES TRÈS HAUTS REVENUS (Seuil D9)
print("\nTop 10 : Communes avec les 10% les plus riches (D9)")
tri_d9 = df.sort_values(by='D921', ascending=False)
print(tri_d9[['CODGEO', 'D921']].head(10))

# 8. LES DIPLOMES
print("\nTop 10 : Habitants avec un diplôme Bac+5 ou plus")
tri_diplomes = df.sort_values(by='P22_NSCOL15P_SUP5', ascending=False)
print(tri_diplomes[['CODGEO', 'P22_NSCOL15P_SUP5']].head(10))

```

Ce code fait une exploration basiques de variables intéressantes. Il nous permet de savoir le top 10 des communes dans des domaines précis : Hôtels, chambres, clientèle senior, clientèle d'affaires, le revenu médian, les revenus très élevés, et le domaine d'étude.

On obtient comme résultat :

Top 10 : Hôtels 5 étoiles

	CODGEO	HT526
29219	75056.0	117.0
29227	75108.0	44.0
28851	73227.0	23.0
29220	75101.0	17.0
32362	83119.0	13.0
29235	75116.0	11.0
29095	74173.0	10.0
29228	75109.0	9.0
29226	75107.0	8.0
29225	75106.0	8.0

Top 10 : Hôtels 4 étoiles

	CODGEO	HT426
29219	75056.0	546.0
29227	75108.0	67.0
29228	75109.0	66.0
1952	6088.0	59.0
29236	75117.0	47.0
29225	75106.0	42.0
29234	75115.0	38.0
27055	69123.0	36.0
1893	6029.0	35.0
26502	67482.0	35.0

--- Top 10 : Chambres 5 étoiles

	CODGEO	HTCH526
29219	75056.0	9505.0
29227	75108.0	3853.0
1893	6029.0	1565.0
29220	75101.0	1484.0
29228	75109.0	1003.0
28851	73227.0	920.0
29235	75116.0	890.0
1952	6088.0	800.0
27055	69123.0	642.0
32362	83119.0	578.0

Top 10 : Chambres 4 étoiles

	CODGEO	HTCH426
29219	75056.0	35820.0
1952	6088.0	5304.0
29234	75115.0	4231.0
34750	95527.0	4219.0
29236	75117.0	4203.0
29227	75108.0	3607.0
29233	75114.0	3502.0
29228	75109.0	3381.0
27055	69123.0	3215.0
25643	65286.0	2752.0

Top 10 : Habitants entre 60 et 74 ans

	CODGEO	P22_POP6074
29219	75056.0	302819.494109
4338	13055.0	134132.259888
1952	6088.0	59821.523024
27055	69123.0	58098.669129
11786	31555.0	54039.041306
16276	44109.0	36869.297597
12987	34172.0	35839.482327
26502	67482.0	35177.719386
29234	75115.0	31880.278220
32380	83137.0	31240.536920

Top 10 : Nombre de cadres

	CODGEO	C22_EMPLT_GS3
29219	75056.0	772594.277877
27055	69123.0	125114.831919
11786	31555.0	119801.081510
29227	75108.0	93283.489710
4338	13055.0	86584.987453
29234	75115.0	79510.370125
16276	44109.0	69489.917969
34498	92026.0	64038.951563
29228	75109.0	62092.008317
12344	33063.0	58501.059908

--- Top 10 : Communes avec le Revenu Médian le plus élevé

	CODGEO	MED21
153	1180.0	55340.0
28954	74016.0	54120.0
28977	74044.0	52900.0
28948	74009.0	51610.0
133	1153.0	49930.0
34510	92051.0	48010.0
29049	74124.0	47300.0
11806	31575.0	46720.0
29014	74082.0	46700.0
124	1143.0	46650.0

Top 10 : Communes avec les 10% les plus riches (D9)

	CODGEO	D921
29226	75107.0	149080.0
29227	75108.0	130390.0
34510	92051.0	128810.0
29225	75106.0	126350.0
29203	74299.0	120470.0
29235	75116.0	119190.0
124	1143.0	109260.0
29014	74082.0	108970.0
28954	74016.0	107400.0
265	1313.0	102330.0

On remarque que c'est souvent la commune 75056 en tête de file

IV. Traitement des données

Après avoir exploré le jeu de données, on a choisi 12 variables pour notre axe d'étude de marché sur les hôtels de luxe.

La liste des variables est : HT426 ,HT526, HTC426 , HTC526, MED21, D921, P22_RSECOCC, RTLIT26, C22_EMPLT_GS3, P22_NSCOL15P_SUP5, P22_POP, P22_POP6074

Il faut maintenant, extraire ces variables pour pouvoir faire des visualisations.

On va utiliser le code suivant :

```
[8]: import pandas as pd

# On charge Le fichier brut

df = pd.read_csv("dossier_complet_clean.csv", sep=';', low_memory=False)

# 2. On fait La Liste exacte de NOS variables pour L'étude
mes_variables = [
    'CODGEO',
    'HT426', 'HT526',
    'HTCH426', 'HTCH526',
    'MED21', 'D921',
    'P22_RSECOCC', 'RTLIT26',
    'C22_EMPLT_GS3', 'P22_NSCOL15P_SUP5',
    'P22_POP', 'P22_POP6074'
]
colonnes_a_mediane = ['D921']
for col in colonnes_a_mediane:
    if col in df.columns:
        # On calcule La médiane sur Les valeurs > 0
        # (On ignore Les 0 qui étaient des 's' ou 'nd')
        valeurs_reelles = df[df[col] > 0][col]

        if not valeurs_reelles.empty: #Si valeur n'est pas vide
            mediane_val = valeurs_reelles.median() #Calcul de La mediane
            # On remplace Les 0 par cette médiane
            df[col] = df[col].replace(0, mediane_val)
            print(f" médiane pour {col} : {mediane_val:.2f}")

# sécurité : on vérifie que Les colonnes existent bien dans Le fichier

colonnes_ok = []
for col in mes_variables:
    if col in df.columns:
        colonnes_ok.append(col)

# 3. On crée un nouveau tableau juste avec nos colonnes
df_final = df[colonnes_ok].copy()

# 4. On crée Le fichier
print("Création du nouveau fichier Excel")

# index=False permet de ne pas rajouter une colonne avec Les numéros de Ligne (0, 1, 2...)
df_final.to_excel("variables_extraites.xlsx", index=False)

print("Terminé")
```

La colonne D921 représente le 9^{ème} décile des revenue en 2021, il n'est pas étonnant que beaucoup ne préfèrent pas le donner, ce qui nous donne une colonne avec beaucoup de valeurs vides

La colonne D921 étant à moitié vide, cela pourrait rendre les graphiques moins intéressants et moins représentatifs. C'est pourquoi on a décidé que pour chaque valeur nul de la colonne, on lui donne la médiane de la colonne, ce sera bien mieux que d'avoir beaucoup de zéro.

Pour le reste des colonnes, on les affecte à une liste mes_variables.


Pour ne pas avoir de problème d'éléments on regarde pour chacun des éléments de mes_variables si ils sont présents dans le dataframe, si ils sont présents, on les ajoute à la liste colonne_ok.

On crée un nouveau tableau df_final comportant uniquement nos colonnes choisies, il ne reste plus qu'à utiliser la fonction to.excel pour les écrire sur un fichier


V. Visualisation

A partir des variables qu'on a prélevées, on a mis en place une série de visualisations qui rentre en lien avec notre axe d'études.


Visualisation 1 — Carte de répartition des hôtels 4 et 5 étoiles Variables : nombre d'hôtels 4 étoiles (HT426) et 5 étoiles (HT526) par commune. Chaque commune est représentée par un point coloré selon la présence ou non d'un hôtel de luxe. Elle permet d'identifier les zones sans offre luxe en France, point de départ de notre analyse




Visualisation 2 — Capacité en chambres 4 et 5 étoiles par département Variables : nombre de chambres 4 étoiles (HTCH426) et 5 étoiles (HTCH526). Ce bar chart compare la capacité d'accueil haut de gamme par département. Il révèle les départements avec beaucoup de chambres 4 étoiles mais peu de 5 étoiles, soit des marchés mûrs pour une montée en gamme




Visualisation 3 — Richesse locale par commune Variables : revenu médian 2021 (MED21) et 9e décile des revenus (D921). Cette carte colorie les communes selon leur niveau de richesse. Elle permet de repérer les communes aisées sans hôtel de luxe : là où la clientèle a le pouvoir d'achat mais l'offre n'existe pas encore



Visualisation 4 — Attractivité touristique par département Variables : résidences secondaires (P22_RSECOCC) et lits en résidences de tourisme (RTLIT26). Ce bar chart identifie les départements touristiques sans hôtel 5 étoiles. Si les visiteurs aisés s'y rendent déjà mais n'ont pas d'hôtel de luxe où séjourner, c'est une opportunité directe.



Visualisation 5 — Concentration de la clientèle CSP+ par département Variables : emplois cadres (C22_EMPLT_GS3) et diplômés Bac+5 (P22_NSCOL15P_SUP5). Ce treemap montre les départements avec la plus forte concentration de cadres et diplômés Bac+5 sans hôtel de luxe. Ce profil correspond exactement à la clientèle cible d'un hôtel 5 étoiles



Visualisation 6 — Concentration de seniors 60-74 ans par département Variables : population totale (P22_POP) et population 60-74 ans (P22_POP6074). Ce bar chart classe les départements selon leur concentration de seniors aisés sans hôtel de luxe. Les 60-74 ans sont le coeur de cible de l'hôtellerie luxe : pouvoir d'achat élevé et temps disponible

